

YOĞUNLUK KIRPMA ALGORİTMASI VE U-NET MODELİ İLE MR GÖRÜNTÜLERİNDE BEYİN TÜMÖRÜ SEGMENTASYONU

Sefa Mert GÜNGÖR, Özgür HADDUR, Ayşe Gül EKER, Meltem Kurt PEHLİVANOĞLU

Bilgisayar Mühendisliği Bölümü

Kocaeli Üniversitesi

Kocaeli, Türkiye

¹meert.gungor@gmail.com, ²ozgurkho@gmail.com, ³

aysegul.eker@kocaeli.edu.tr

Özetçe- Beyin tümörleri, beyinde bulunan hücrelerin veya kitlenin anormal büyümesi sonucunda oluşmaktadır. Her tümör çeşidi ölümcül sonuçlara yol açıyor olmasa da hastanın genel durumu için oldukça önemli durumlara neden olmaktadır. Bulunan tümör iyi huylu olsa dahi fark edilmediği sürece hasta için son derece tehlikelidir. Bu çıkarım ile beyin tümörlerini erken fark etmek, kontrol altında tutmak ve doğru bir şekilde müdahale etmek oldukça önemlidir. MRI (Manyetik Rezonans Görüntüleme) tekniği canlı varlıkların iç yapısını güçlü bir manyetik alana tabi tutarak gelen sinyallerden görüntü oluşturma mantığı ile çalışmaktadır. Canlı vücudunun tamamında kullanılıyor olsa da beyin hastalıklarının, özellikle de beyin tümörlerinin teşhisinde başarısını kanıtlamıştır. MRI görüntülerinin en çok kullanılan türleri T1, T2 ve Flair olarak isimlendirilir. Her bir türün özellikleri birbirlerinden farklılık göstermektedir. Bu çalışmada farklılıklar gözetilerek BRATS20 veri setinde, T1ce görüntülerinin üzerinden beyin tümör tespiti yapılmıştır. Segmentasyonun gerçekleşmesi için evrimsel sinir ağları (CNN) kullanılarak geliştirilen U-Net modeli kullanılmıştır. Segmentasyonun başarısını arttırmak için piksel yoğunluğunun eşit dağılımını sağlayan çeşitli ön işleme adımları gerçekleştirilmiştir. İki farklı model eğitimi gerçekleştirilmiştir. İlk eğitim genişleyen tümör bölgesi ile gerçekleşmiştir. Bu eğitimin validasyon dice_coef benzerlik oranı %80 dir, doğruluk oranı %92 olup validasyon doğruluk değeri de %70 olarak ölçümlenmiştir. İkinci eğitim için ise nekroz ve genişleyen tümörün birlikte bulunduğu veriler kullanılmıştır bu eğitim için validasyon dice_coef benzerlik oranı %75'tir, doğruluk oranı %96 olup validasyon doğruluk değeri de %65 olarak ölçümlenmiştir.

..

Abstract- Brain tumors are caused by abnormal growth of cells or mass in the brain. Although not every type of tumor leads to fatal consequences, it causes very important conditions for the overall condition of the patient. Even if the tumor is benign, it is extremely dangerous for the patient unless it is noticed. With this inference, it is very important to notice brain tumors early, keep them under control and intervene correctly. MRI (Magnetic Resonance Imaging) technique works with the logic of creating images from incoming signals by subjecting the internal structure of living beings to a strong magnetic field. Although it is used throughout the living body, it has proven successful in the diagnosis of brain diseases, especially brain tumors. The most commonly used types of MRI images are T1, T2, and Flair. The characteristics of each species differ from each other. In this study, brain tumor detection was performed on T1ce images in the BraTS20 data set, taking into account the differences. The U-Net model, developed using convolutional neural networks (CNN), was used to achieve segmentation. To

increase the success of segmentation, various preprocessing steps have been performed that ensure an even distribution of pixel density. Two different model trainings were carried out. In first training took place with the enhancing tumor site. The validation dice_coef similarity rate of this training is 80%, the accuracy rate is 92% and the validation accuracy value is 70%. For the second training, data on necrosis and enhancing tumor were used together for this training, the validation dice_coef similarity rate is 75%, the accuracy rate is 96%, and the validation accuracy value is 65%.

I.

GİRİŞ

İnsanın görsel algılama yapısı herhangi bir obje algılama görevi için oldukça hızlı ve hassastır. İnsanlar az bir bilinçle bile bir aracı sürebilmek gibi kompleks bir görevi yerine getirebilirler. İnsanların aksine bilgisayar sistemleri gerçek zamanlı nesne algılayabilmek için büyük eğitim verilerine, yardımcı olacak cihazlara, karmaşık algoritmalara ve sensörlere ihtiyaç duyar. Böylesine karmaşık bir görevi yerine getirebilmek için sinir ağları ve yapay zekâ yöntemleri geliştirilmiştir.

Yapay zekanın hızla gelişmesi; tıbbi görüntüleme ve bilgisayar yardımıyla tıbbi müdahalenin gelişimi ile bu konuda araştırma yapan görevlilerin tıp alanında bilgisayar destekli tespit sistemlerini kullanmalarına destek sağlamıştır. Bu sistemler araştırmacılara yardımcı olarak tespitteki yükü büyük ölçüde azaltmaktadır. Derin öğrenme radyoloji uzmanlarının daha doğru ve daha hızlı bir şekilde tanı koyabilmelerine olanak sağlar. Ayrıca bu sistemler medikal görüntü analizi için doktorların tanı koymasına yardımcı olmaktadır. Bu sebeplerden dolayı beyin tümörlerinin tespiti gibi tıbbi görüntü algılama problemleri araştırmacıların dikkatini çekmektedir.

MRI (Manyetik Rezonans Görüntüleme) tekniği canlı varlıkların iç yapısını daha detaylı bir şekilde görüntülenmesini sağlar ve hastalıkların tespitinde yardımcı rol oynar. Bu taramalar çoğunlukla diğer görüntüleme yöntemlerinden daha fazla maliyete neden olmakta ve gerçekleştirilmesi büyü bir zaman almaktadır. Bu görüntüler kayıt edilirken kişinin hareketsiz kalabilmesi ve nefesini tutma talimatlarını yerine getirmesi ile görüntülerin kalitesi artmaktadır. Sonuç olarak MRI görüntülemesi ile beyin hastalıklarının özellikle de beyin tümörünün tespiti kolaylaşmaktadır.

II. LİTERATÜR

Bu konuyla ilgili daha önceden yapılan çalışmalar bulunmaktadır.

2009 yılında Gajanayake ve arkadaşları tarafından [1] yapılan çalışmada mevcut olan pek çok segmentasyon metodu için bazı sonuçlar elde edilmiştir, bunlar bu metodun analizi ve başarımlarının hesaplamaları sonucunda yapılmıştır. Bu metodla ilgili deneysel uygulamalar gerçekleştirilmiştir. Bu uygulamalarda en başarısız olandan en başarılı olana doğru bir sıralama çıkarılmıştır: One Seed Region Growing, Two Seed Region Growing, Iterative thresholding, Continuum Topolojik Derivative, Ayrık Topolojik Derivative, Expectation Maximization, Fuzzy C-Means, K-Means, Mean Shift, Otsu şeklindedir.

2014 yılında Kurat ve Özkaya tarafından sunulan bir çalışmada [2] bir beyin MR görüntüsü kullanılarak beyin tümörleri ile ilgili bazı bulgular elde edilmiştir. Bu bulgularla beyin tümörlerinin lokasyonu saptanmış olup büyüklük bilgisi ve kapladığı alanın etrafını sınırlayan bölge bilgilerinin açık bir şekilde ve otomatik olarak elde edilmesi sağlanmıştır. Hybrid Geodesic Region Based Curve Evolutions for Image Segmentation ile bir yarı otomatik sistem uyarlanmış ve istenen MR görüntülerinde başarımlar %70 ölçümlenmiştir.

2015 yılında Zhou ve arkadaşları tarafından yapılan çalışmada [3] bir segmentasyon işlemi yapılmıştır. Bu segmentasyon işlemi için çözünürlüğü yüksek ve 2D boyutu bulunan MR görüntülerinde Firefly ve Otsu algoritmaları kullanılmıştır. Yapılan bir çıkarımla birlikte daha az bir hesaplama zamanında doğru segmentasyon işlemi yapıldığı gözlemlenmiştir.

Prema ve arkadaşları tarafından yapılan 2016 yılında yapılan bir çalışmada [4] Otsu algoritması kullanılarak beyin hücresi içinde konumlanmış kanser hücrelerinin tespiti sağlanmıştır.

2017 yılında Havaei ve arkadaşları tarafından yapılan çalışmada [5] Deep Neural Network (DNN) kullanılarak özgün bir mimari hazırlanarak tespit sağlanmıştır. Veri seti olarak 2013 BraTS kullanılmış olup başarılı bir sonuç elde edilmiştir. Bu mimari ile tümörün büyüklüğü, şekli ve görüntü özelliklerinin önemi bulunmaktadır.

2016 yılında G. B. Praveen ve A. Agrawal [6] tarafından yapılan çalışmada MR görüntülerinde tümör tespitini gerçekleştirmek için çok aşamalı bir yaklaşım sunulmuştur. Bu yaklaşımın ilk adımı, görüntü filtreleme, görüntü kırpması, ölçekleme ve histogram eşitlemeyi içeren ön işlemdir. Özellik ekstraksiyonu daha sonra GLCM, gri seviye çalışma uzunluğu matrisi (GLRLM) ve histogram tabanlı teknikler kullanılarak gerçekleştirilmiştir. Random Forest algoritması

sınıflandırıcı olarak kullanılmıştır. Çalışmanın sonunda, aktif bir kontur modeli kullanılarak hızlı sınırlayıcı kutu ve tümör segmentasyonu kullanılarak tümör tespiti yapılmıştır. Model performansını değerlendirmek için toplam 120 hasta Verisi kullanılmıştır ve modellerinin sınıflandırma doğruluğu %87.62'dir.

2015'te Olaf Ronneberger, Philipp Fischer ve Thomas Brox [7] tarafından yapılan çalışmada şu sonuçlar çıkarılmıştır. UNET ilk olarak biyomedikal görüntüleri işlemek için 2015 yılında tasarlanmış ve uygulanmıştır. Biyomedikal vakalarda, sadece hastalığın varlığını değil, aynı zamanda anormalliğin lokalizasyonunu da tahmin etmek önemlidir. Unet, sınırları yerelleştirerek ve ayırt ederek bu sorunu çözmeye kendini adanmıştır, her pikselde sınıflandırma yapmaktır, böylece giriş ve çıkış aynı boyutu paylaşmaktadır.

2020 yılında Liu ve diğ. [8] tarafından yapılan derlemede; mimarilere, genişletilmiş mekanizmalara ve uygulama alanlarına odaklanan tıbbi görüntü segmentasyon görevlerine uygulanan U-Net modelinin kapsamlı bir literatür incelemesi sunulmuştur. Farklı genişletilmiş U-net modelleri incelenip, artık mekanizma, yoğun mekanizma, dilate mekanizma, dikkat mekanizması, çok modüllü mekanizma ve topluluk mekanizması dahil olmak üzere ana gelişmiş genişletilmiş mekanizmalar karşılaştırılıp artıları ve eksileri analiz edilmiştir. Bu araştırma; beyin tümörü, inme, beyaz cevher hipertansiyonları (WMHs), göz, kalp, akciğer, kas-iskelet sistemi, cilt kanseri ve nöronal patoloji dahil olmak üzere U-net in ana uygulama alanlarındaki çalışmalarına genel bir bakış sağlamaktadır.


III. YÖNTEMLER

Görüntü bölütleme, görüntü içerisinde bulunan her bir farklı bölgeyi farklı etiketlerle ayırmak için kullanılmaktadır. Görüntü içerisinde benzer parlaklık değerleri olabilir. Bu parlaklık değerleri farklı bölgelerdeki nesneleri temsil eder. Segmentasyon uygulamalarına ek olarak hareket eden araçlar, hareket eden yayalar, yol kenarında bulunan ağaçlar gibi nesneleri ayırt etmek için kullanılan örnekler verilebilir. Bu çalışmada evrimsel sinir ağı altyapısına dayanan U-Net beyin tümörü tespiti için kullanılmıştır.

A. CNN (Convolutional Neural Networks)

CNN, başlangıçta görsel korteksten esinlenen bir tür çok katmanlı bir ileri beslemeli yapay sinir ağıdır ve buna özetle çok katmanlı sensör (MLF) de denebilir. CNN, derin öğrenmenin önemli kavramlarından biridir. CNN genel olarak görüntü algılama uygulamalarında kullanılır, konvolüsyon ve havuzlama olarak bilinen iki temel yöntemi bulunmaktadır. Yüksek düzeyde sınıflandırma doğruluğuna sahip olana kadar,


konvolüsyon ve havuzlama katmanları düzenlenir. Ek olarak, her bir kıvrımlı katmanda bazı özellik haritaları bulunabilir ve aynı haritadaki kıvrımlı düğümlerin ağırlıkları paylaşılır. Bu düzenlemeler, izlenebilir parametrelerin sayısını korurken ağır farklı özelliklerinin öğrenilmesine izin verir. CNN, geleneksel yöntemlere kıyasla daha az özelleşmiş bir göreve sahiptir ve özellikleri tamamen otomatik olarak çıkarmayı öğrenir.



Şekil 1-CNN

B. Semantik Segmentasyon

Piksel tabanlı sınıflandırma olarak da bilinen semantik segmentasyon, bir görüntünün her pikselini belirli bir sınıfa ait olarak sınıflandırdığımız önemli bir görevdir. U-net, Mask R-CNN, Feature Pyramid Network (FPN), vb.gibi birçok semantik segmentasyon algoritması vardır. Bu çalışmada, esas olarak en iyi tanınan görüntü segmentasyon algoritmalarından biri olan U-net'e odaklanılmıştır ve temel mantık tüm algoritmalarda aynıdır.

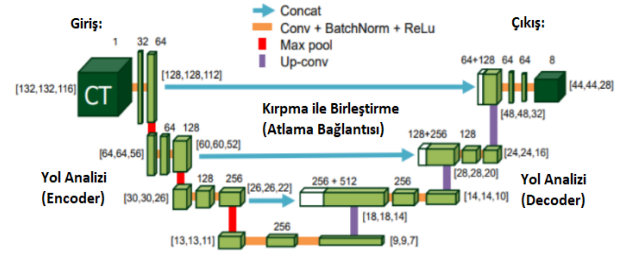


Şekil 2-Semantik Segmentasyon

C. U-Net

Almanya'daki Freiburg Üniversitesi Bilgisayar Bilimleri Bölümü'nde, biyomedikal görüntü segmentasyonu için geliştirilen bir evrimsel sinir ağıdır. Ağ tamamen evrimsel sinir ağları üzerine kuruludur ve mimarisi, daha az eğitim görüntüsü ile çalışmak ve daha hassas bölümlere sağlamak için genişletilmiştir [9]. U-net ilk olarak biyomedikal görüntü segmentasyonu için kullanılmıştır. Mimarisi genel olarak bir kodlayıcı ağı ve ardından bir kod çözücü ağı olarak düşünülebilir. Derin ağı nihai sonucunun tek önemli şey olduğu sınıflandırmadan farklı olarak, semantik segmentasyon sadece piksel düzeyinde ayrımcılığı değil, aynı zamanda

kodlayıcının farklı aşamalarında öğrenilen, ayırt edici özellikleri piksel alanına yansıtmak için bir mekanizma gerektirir.




Şekil 3- U-Net

IV. DENEYSEL ÇALIŞMA

Çalışmada beyin segmentasyonu için oldukça güncel olan BRATS20 veri seti kullanılmıştır. Bu veri setinde veriler Nifti formatında bulunmaktadır ve her bir hastanın beyin MR görüntüleri 4 farklı sekansta alınan MR görüntü çeşidinde kaydedilmiştir. Flair, T1,T1ce,T2 ve radyoloji uzmanları tarafından manuel olarak çıkarılmış segmentasyon görüntüleri şeklindedir.369 Adet Hasta MR Görüntüsü mevcuttur. Öncelikle Flair ve T2 görüntüleri üzerinden tümör tespiti yapılmıştır. Bu görüntülerin birleştirilmelerinin amacı ise birbirlerinin üzerinde konumlandırıldıkları zaman daha açık bir şekilde tümör tespiti yapılmasıdır. U-Net modelinin birleştirilen görüntüler ve radyoloji uzmanları tarafından manuel olarak çıkarılmış segmentasyon görüntüleri ile eğitimi sağlanmıştır. Model bu verilerle eğitildikten sonra modele tahmin yapabilmesi için test verileri verilmiştir. Burada ölçüm dice_coef ile yapılmıştır. Dice Coefficient, iki veri kümesi arasındaki benzerliği ölçen istatistiksel bir araçtır. Bu indeks, AI ile oluşturulan görüntü segmentasyon algoritmalarının doğrulanmasında tartışmasız en yaygın kullanılan araç haline gelmiştir.


Test sonucunda ortaya çıkan tahminler başarı oranı yüksek seviyede sonuçlar çıkarmıştır. %30 test verisi verilmiştir, %92 oranında dice_coef değeri ölçümlenmiştir.




Şekil 4-T2 ve Flair Tahmini

Çalışmanın ikinci adımında da BRATS20 veri seti kullanılmıştır. Bu aşamada T1ce formatlı MR

görüntüleri üzerinden tümör tespiti yapabilmek için çalışılmıştır. Öncelikle ilk eğitim için modelde kırılmamış T1ce görüntüleri kullanılmıştır. Fakat modele eğitim için verilen T1ce görüntüleri, önceki adımda modele eğitim için verilen Flair ve T2 MR görüntülerinin verdiği başarılı sonuçları vermemiştir. Çünkü piksel dağılımında büyük bir eşitsizlik olduğu gözlenmiştir. T1ce görüntülerinin tümör tespiti hakkında yapılan incelemeler sonucunda bir önilem ile kırılarak modele verildiği takdirde daha başarılı sonuçlar verdiği gözlenmiştir. Daha sonra kırma için literatürde bulunan algoritmalar ve fonksiyonlar [10] kullanılmıştır. Bu denemeden başarılı bulgular elde edilmiştir fakat bu kırma işlemine radyoloji uzmanları tarafından segmente edilen MR görüntüleri dahil edildiği için kullanımı uygun bulunmamıştır.




Şekil 5- Hazır Algoritma ile Kırılmış T1ce Tahmini



Şekil 6- Özgün Algoritma ile Kırılmış T1ce Tahmini

Çıkarılan sonuca göre özgün bir kırma algoritması hazırlanmaya karar verilmiştir. Algoritma 240*240 olan MR görüntüleri üzerinde 64*64 bir çerçeve ile x ve y koordinatlarını sırasıyla dolaşarak tüm görüntüyü taramaktadır. Bu işlemin mantığı ise görüntü üzerinde bulunan yoğunluğa göre genlik değeri en yüksek olan 64*64'lük bölgeyi tümör olma olasılığı göz önünde bulundurarak seçmesidir ve seçtiği bölgeye göre kırma işleminin gerçekleştirilmesidir. Kırılan T1ce MR görüntüleri ve radyoloji uzmanları tarafından manuel olarak çıkarılmış segmentasyon görüntüleri ile model eğitilmiştir. Eğitilen modele yabancı olan test verileri geliştirilen kırma algoritmasına göre kırma işlemi

yapıldıktan sonra verilmiştir. Sonuç olarak özgün bir algoritma ile kırılan modele yabancı olan T1ce MR görüntüleri üzerinden tümör tahmini yapılmıştır. Yapılan tümör tahminlerine bakıldığı zaman yaklaşık %90 oranında benzerlik tespit edilmiştir. İki farklı model eğitimi gerçekleştirilmiştir. İlk eğitim genişleyen tümör bölgesi ile gerçekleştirilmiştir. Bu eğitimin validasyon dice_coef benzerlik oranı %80 dir, doğruluk oranı %92 olup validasyon doğruluk değeri de %70 olarak ölçümlenmiştir. İkinci eğitim için ise nekroz ve genişleyen tümörün birlikte bulunduğu veriler kullanılmıştır bu eğitim için validasyon dice_coef benzerlik oranı %75'tir, doğruluk oranı %96 olup validasyon doğruluk değeri de %65 olarak ölçümlenmiştir.



Şekil 7- Özgün Kırma Algoritmasının Mantığı

V. SONUÇLAR VE TARTIŞMA

Beyin tümörleri; beyinde bulunan hücrelerin anormal derecede artması veya kitlelerin büyümesidir. Pek çok beyin tümörü çeşidi bulunur ve ölümcül olmasa dahi erken tanısı ve tedavisi çok önemlidir. Mr beyin hastalıklarının tanısında kullanılan en önemli yöntemdir. MR görüntülerinin yanlış yorumlanması, yorumlanmanın oldukça uzun vakit alması olası problemlerdir.

Bu çalışmada T1ce görüntüleri, geliştirdiğimiz algoritma ile başarılı bir şekilde kırıldıktan sonra bu görüntüler ve radyoloji uzmanı tarafından manuel olarak segmente edilmiş görüntüler modelin eğitiminde kullanılmıştır. Tümör olan bölge; yani genişleyen tümör ve nekroz bölgesi için doğru bir şekilde tümör tahminleri yapılmıştır. Beyin tümörü segmentasyonu için oldukça güncel olan Brats20 veri seti kullanılmıştır.

Diğer çalışmalardan farklı olarak özgün bir kırma algoritması ile T1ce sekansındaki Mr görüntüleri için bir tümör tahmini yapılmıştır. Bu tahminden başarı oranı yüksek bir sonuç ortaya çıkmıştır. Gelecekte farklı tümör türleri için de kırma algoritması kullanılarak önilem gerçekleştirilerek tahmin başarıları artırılabilir.

Bu çalışma ile tıp alanında çalışan uzmanlar için oldukça uzun süren MR yorumlama işlemini kısaltarak, otomatik çıkarım yapmak amaçlanmıştır.

VII. KAYNAKÇA

1. Gajanayake, G. M. N. R., Roshan Dharshana Yapa, B. Hewawithana. 2009. "Comparison of standard image segmentation methods for segmentation of brain tumors from 2D MR images." Industrial and Information Systems (ICIIS), 2009 International Conference on. IEEE. DOI: 0.1109/ICIINFS.2009.5429848
2. Kurat, N., Ozkaya N. 2014. Automaticly extracting brain tumor from MR image, Signal Processing and Communications Applications Conference (SIU) on IEEE, 22nd. IEEE, 1532-1535. DOI: 10.1109/SIU.2014.6830533
3. Zhou, Chenhang, et al. 2015. "A method of Two-Dimensional Otsu image threshold segmentation based on improved Firefly Algorithm." Cyber Technology in Automation, Control, and Intelligent Systems (CYBER), International Conference on IEEE. DOI: 10.1109/CYBER.2015.7288151
4. Prema, V., M. Sivasubramanian, and S. Meenakshi. 2016. "Brain cancer feature extraction using otsu's thresholding segmentation." BRAIN 6.3.
5. Havaei, M., Davy, A., Warde-Farley, D., Biard, A., Courville, A., Bengio, Y., ... & Larochelle, H. 2017. Brain tumor segmentation with deep neural networks. Medical image analysis, 35: 18-31. DOI: 10.1016/j.media.2016.05.004
6. Praveen GB, Agrawal A. Multi stage classification and segmentation of brain tumor. In: 3rd International Conference on Computing for Sustainable Global Development (INDIACom); 16-18 March 2016; New Delhi, India. pp. 1628-1632.
7. https://www.researchgate.net/publication/341826320_A_Survey_on_U-shaped_networks_in_Medical_Image_Segmentations
8. "UNET: Convolutional Networks for Biomedical Image Segmentation", Olaf Ronneberger, Philipp Fischer, and Thomas Brox, Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. MICCAI 2015. Lecture Notes in Computer Science, vol 9351. Springer Cham.
9. <https://ayyucekizrak.medium.com/g%C3%B6r%C3%BCnt%C3%BC-b%C3%B6l%C3%BCtleme-segmentasyon-i%C3%A7in-derin-%C3%B6l%C4%9Frenme-u-net-3340be23096b>
10. <https://www.udemy.com/course/deep-learning-ve-python-adan-zye-derin-ogrenme-5/>